

SE ChatBot

# Overlap & Reranking

RAG 성능을 올리려고 당연히 적용했던 두 가지 기법이  
왜 우리 데이터에서는 통하지 않았는가?

조원 : 엄태원, 서성훈, 정서인

---

Overlap(겹침 분할) · 리랭킹(검색 결과 재정렬)

# 오늘 할 이야기

---

- 지난 발표 – 청킹 방식 : 문서를 500토큰씩 자름.
- 이번에는 Overlap과 모델 리랭킹을 적용해 검색 정확도와 응답 시간을 비교.
- **두 방법 모두 전체 평균을 안정적으로 높이지 못했기에, 오늘은 원인과 다음 단계를 공유함.**

## 시도 ①

### Overlap

청크 사이에 문맥 겹치기

## 시도 ②

### 리랭킹

검색 후보 순서 다시 계산

## 다음 단계

### 프롬프트 전략

답변 규칙을 반복 검증

# 검색 품질은 Recall@3로 측정

질문 300개마다 정답 문서를 지정하고,  
그 문서가 검색 결과 상위 3개에 포함됐는지 확인.

```
{
  "qid": "web200_kumoh-notice-43682",
  "query": "연구활동종사자 정기안전교육은 언제까지 이수해야 하나요?",
  "source_category": "행정·안내",
  "source_type": "se게시판",
  "gold_document_ids": [
    "kumoh-notice-43682"
  ],
  "expected_evidence": [
    "이수 마감일은 5월 30일",
    "안전교육 이수율이 저조하다는 안내"
  ],
  "answer_checkpoints": [
    "이수 기한 확인"
  ],
  "source_document": {
    "source": "se게시판",
    "category": "행정·안내",
    "published_at": "2025-05-09"
  }
},
{
  "qid": "web200_kumoh-notice-41711",
  "query": "졸업요건에 대한 공지가 여러 번 있었는데, 꼭 확인해야 할 사항은 무엇인가요?",
  "source_category": "학적·졸업",
  "source_type": "se게시판",
  "gold_document_ids": [
    "kumoh-notice-41711"
  ],
  "expected_evidence": [
    "취업진로교육과 상담 요건이 포함됨",
    "입학년도에 따라 졸업기준이 다름"
  ],
  "answer_checkpoints": [
    "졸업요건 확인 및 충족 여부 점검"
  ],
  "source_document": {
    "source": "se게시판",
    "category": "학적·졸업",
    "published_at": "2025-02-07"
  }
},
}
```

## 평가 지표

### Recall@3

정답 문서가 검색 상위 3개 안에  
포함된 질문의 비율

**Recall@3 = 0.60이면**

100개 질문 중 60개에서 정답 문서가  
상위 3개에 포함됨을 의미.

\* Recall@3: 정답 문서가 검색 결과 상위 3개에 포함된 질문의 비율

# Overlap 점수는 일정한 방향으로 변하지 않았음

Overlap : 앞 청크의 끝부분을 다음 청크 앞부분에 포함하는 분할 방식.  
문장이 중간에 끊기는 걸 막으려고 대부분의 RAG에서 선택하는 방식.

| Overlap 토큰 수 | 0 (미적용)      | 50           | 100          | 150          |
|--------------|--------------|--------------|--------------|--------------|
| Recall@3     | 0.875        | 0.850        | 0.838        | 0.863        |
| Recall@5     | <b>0.912</b> | <b>0.950</b> | <b>0.900</b> | <b>0.938</b> |
| 청크 개수        | 1,474        | 1,503        | 1,531        | 1,581        |

## 관찰 결과

Overlap을 50·100·150토큰으로 바꿨지만, Recall@3·Recall@5가 같은 방향으로 움직이지 않았습니다.  
특정 설정의 한 번 개선만으로 효과를 판단할 수 없음을 의미.

## 문서 58.4%에는 Overlap 경계가 없음

| 분할 후 청크 수 | 문서 수 | 비율    |
|-----------|------|-------|
| 1개 (미분할)  | 496  | 58.4% |
| 2개        | 208  | 24.5% |
| 3개        | 79   | 9.3%  |
| 4개 이상     | 67   | 7.9%  |

58.4%

문서 하나가 한 청크로 유지됨

문서 길이의 중앙값

445 토큰

분할 기준(500토큰)보다 짧음

### 해석

문서가 한 청크로 유지되면 겹칠 경계가 없습니다. 따라서 496개 문서(58.4%)에서는 Overlap이 작동하지 않았습니다.

## 분할 경계의 89%가 문장 끝과 일치

### Overlap이 필요한 경우

앞뒤 내용이 이어지고, 문장이 경계에서

끊기면 의미가 달라지는 문서

### 우리 데이터

"신청 기간"."제출 서류"."유의사항"처럼  
문단별 정보가 독립적인 공지

89%

분할 경계의 89%가  
문장 끝과 일치

문단 → 목록 → 문장 순서로 경계를 찾는  
분할 규칙이 문장을 보존함

### 해석

문장 중간에서 끊긴 경계는 약 11%였기에, Overlap으로 보완할 대상이 적었음.

# 문서가 길어지면 Overlap이 살아날까?

정답 문서 길이별로 Recall@3를 재계산.

| 정답 문서 길이      | 질문 수 | Overlap 없음 | Overlap 적용 | 점수 차이  |
|---------------|------|------------|------------|--------|
| 500 토큰 이하     | 142  | 0.634      | 0.613      | -0.021 |
| 500 ~ 1,000   | 90   | 0.589      | 0.578      | -0.011 |
| 1,000 ~ 1,500 | 40   | 0.525      | 0.625      | +0.100 |
| 1,500 이상      | 28   | 0.500      | 0.571      | +0.071 |

1,000토큰 이상에서는  
**Recall@3가 상승**

해당 질문은 68개,  
**전체의 23%**

## 해석

Overlap은 1,000토큰 이상 문서에서 도움이 됐지만, 문서 수는 전체 질문의 23%에만 해당함.  
전체 평균에서는 개선 효과가 나타나지 않음.

\* 점수 차이 = Overlap 적용 Recall@3 - 미적용 Recall@3

# 분할 설정을 바꿔도 점수 차이는 0.01 미만

500토큰 설정에 한정된 결과인지 확인하려고, 분할 크기와 방식을 재측정.

| 실험 설정                | Overlap 없음 | Overlap 적용 | 점수 차이  |
|----------------------|------------|------------|--------|
| 300 토큰씩 자르기          | 0.617      | 0.610      | -0.007 |
| 500 토큰씩 자르기          | 0.593      | 0.600      | +0.007 |
| 1000 토큰씩 자르기         | 0.623      | 0.620      | -0.003 |
| 재귀 분할(recursive) 500 | 0.597      | 0.587      | -0.010 |

0.01

모든 설정의 차이가  
이 값보다 작음

## 적용 여부 확인

재귀 분할에서는 모든 분할 경계에 Overlap이 적용된 것을 확인함.  
따라서 적용 누락이 원인은 아님.

\* 재귀 분할(recursive): 문단 → 문장 → 공백처럼 큰 경계부터 순서대로 문서를 나누는 방식



## 리랭킹도 붙여봤지만 마찬가지로

리랭킹은 검색 후보 50개의 관련도를 별도 모델로 다시 계산해 순서를 재배치하는 단계.

| 방식           | Recall@3 | Recall@5 | 리랭킹 시간   |
|--------------|----------|----------|----------|
| 리랭킹 안 함 (기준) | 0.593    | 0.740    | 0 ms     |
| BGE 모델       | 0.520    | 0.690    | 1,736 ms |
| Qwen3 모델     | 0.630    | 0.727    | 2,222 ms |

2.2초

Qwen3 리랭킹 시간  
기본 검색은 약 3ms

### 결정

Qwen3는 Recall@3를 0.037 높였지만 Recall@5는 0.013 낮췄고, 2.2초의 지연이 추가됐음. 따라서 미적용

## 유사한 후보 문서가 리랭킹 효과를 제한한 원인일까?

1. 검색 후보 대부분이 같은 학과 게시판의 비슷한 공지.
2. 후보 간 차이가 작으면 순서를 바꿀 단서도 줄어들.

76%

평가 데이터 중  
학과 게시판 출처

30%

연도·학기만 다른  
동일 제목 공지

55%

상위 5개 검색 점수의  
차이가 작은 질문

세 지표는 후보 문서의 유사성이 높다는 정황임을 알 수 있음. 이것이 리랭킹 개선 폭을 제한했는지는 추가 검증 과제.

### 현재 결론 — 가설

후보 유사성이 원인이라는 해석은 아직 검증되지 않았기에, 추후 검증 과제로 문서 유형별 성능 비교로 확인할 것.

\* 퍼센테이지는 전체 문서량을 기준으로 선정.

# RAG 챗봇의 답변 규칙을 네 가지로

많이 쓰이는 RAG 프롬프트 전략을 조사해, 챗봇이 따를 1차 답변 규칙을 작성했습니다.

1

**후속 질문을 독립형 검색 질문으로 바꾼다**

"그럼 승인 안 되면?" → "수강지도 상담 미승인 시 제한"

2

**검색 문서만 근거로 답하고 출처를 표시한다**

근거가 없으면 '확인할 수 없음'이라고 답하고 추측하지 않는다

3

**문서 유형에 따라 출처 우선순위를 정한다**

일정·신청은 공식 공지를 우선하고, 후기는 참고 정보로 구분한다

답변 형식 — 핵심 답변 → 근거 → 출처 → 확인이 필요한 내용

# 프롬프트 전략 설정

실제로 자주 묻는 질문에서 실패 사례를 찾아 규칙을 보완.

1

**팀원이 자주 묻는 질문과 후속 질문을 입력한다**

예: '수강지도 상담이 뭐야?' → '승인 안 되면?'

2

**답변 오류를 유형별로 기록한다**

문맥 누락 / 근거 없는 답변 / 잘못된 출처 / 과도하게 긴 답변

3

**오류를 줄이는 규칙·예시를 하나씩 수정한다**

변경 전후에 같은 질문 세트로 다시 비교한다

최종 발표 전까지 — 질문 → 실패 기록 → 프롬프트 수정 → 재검증을 반복

## 최종발표 : 챗봇 시연

| 시연 항목       | 구현 내용      | 시연에서 확인할 점          |
|-------------|------------|---------------------|
| 실제 질의응답     | 문서 검색 후 답변 | 답변과 출처가 일치하는지       |
| 후속 질문       | 대화 맥락 반영   | 앞 질문과 자연스럽게 이어지는지   |
| 자주 묻는 질문 캐싱 | 답변 저장.재사용  | 같은 질문의 응답 시간이 줄어드는지 |
| 근거 부족       | 근거 없음 안내   | 추측 답변을 막는지          |

- ✓ 실제 챗봇에서 질문 → 검색 → 답변 → 출처 표시를 한 흐름으로 시연합니다
- ✓ 팀원 질문으로 후속 질문 처리와 근거 없는 답변 차단을 확인합니다
- ✓ 같은 질문의 캐시 적용 전후 응답 시간을 비교합니다

\* 캐싱(caching): 자주 반복되는 질문의 답변을 저장해 같은 요청에 빠르게 재사용하는 방식

## 이번에 배운 것

---

| 시행한 전략    | 결정     | 이유                    |
|-----------|--------|-----------------------|
| 청킹 500 토큰 | 그대로 유지 | 우리 문서 길이(중간값 445) 최적값 |
| Overlap   | 쓰지 않음  | 성능개선이 유의미하지 않음        |
| 리랭킹       | 지금은 보류 | 성능개선은 미미하며, 답변지연만 증가. |
| 프롬프트 전략   | 다음에 구현 | 이어지는 질문 처리가 필요        |